



AI Agent ワークショップ TOKYO

2026.06





“All LLM frontier labs will do this (autoresearch). It's the final boss battle. It's a lot more complex at scale of course - you don't just have a single train.py file to tune. But doing it is "just engineering" and it's going to work. - Andrej Karpathy”

[X](#), [github](#)

「すべてのフロンティアLLMラボは、これ（自動研究）をやるようになる。これはラスボス戦だ。もちろん、大規模にやるとなるとはるかに複雑になる。単に1つの train.py ファイルをチューニングすればいい、という話ではない。だが、それを実現することは“ただのエンジニアリング”であり、うまくいくことになる。」

— アンドレイ・カルパシー


自律的改善ループの実現

- **W&B SkillsとMCPサーバーにより、**
Claude Code, Codexなどのコーディングエージェントが実行時にW&Bへ接続可能
- Coding Agentの性能を最大限に引き出すためには、十分な情報が検索可能な形で保存・抽出できる必要がある。W&B, W&B Skillsを使うことで、W&B で個人に寄らない、ベストクラスのCoding Agentのハーネスが実現できる

Key value

イテレーション速度を飛躍的に向上 — インサイトから改善までのループを自動化

W&BとW&B Skillsが、AI Agentのバージョン・評価結果・プロダクション時の利用データの保存と抽出の安定したハーネスとなる




- **W&B Skills**
- **W&B MCP**

Coding Agent ネイティブなAI開発に向けたその他サービス



[wandb/senpai](https://wandb.com/senpai)



- W&B Skills, k8s, Githubを用いた自律的モデル改善のテンプレート
- 評価関数が明確な場合に有効

[AI Engineering Dojo](https://www.codewithrobot.com/ai-engineering-dojo)



- AI AgentをCoding Agentで改善するオンライン学習コース
- 評価基準が決まっておらず、人手評価から始める必要がある開発で有効

このハンズオンのGoal



- 評価体系を1から作りながら、**Coding Agent**と**Weave**で改善をする**AI Agent**開発を体験



- ハーネスとして機能する **Weave**を理解し、自分のユースケースへの適用を考える
- (できれば) 今日学んだ内容やさらに深掘りした内容は是非ブログにしたり、**SNS**で発信してください



easy
AI is ~~hard~~ to productionize.

Weights & Biases
by CoreWeave

Edit profile

Weights & Biases Japan ✓
@wandbjapan

Show translation

Weights & Biases Japan の公式Xアカウントです。W&Bに関する情報を発信していきます！

Joined January 2026 >

20 Following 148 Followers



@wandbjapan

Discovery forge



Agentを用いたAI Agent・モデルを改善する tipsやツールを毎日検索し、それらの情報をリストアップするダッシュボード

https://ai-eng-dojo.com/app/discovery_forge

The screenshot shows the Discovery Forge dashboard within the AI Engineering Dojo interface. At the top, there's a navigation bar with the Dojo logo, 'Weights & Biases' integration, and a user profile icon. The main header features the 'Discovery Forge' title and a subtitle: 'An AI agent that runs every day, scanning the web for research, repositories, papers, and product updates related to Auto Research.' Below this, it lists the repository 'wandb / discovery-forge', the W&B dashboard 'wandb-smile / traces', and a sync status '2026-05-18 synced unknown'. A search bar is present with the placeholder 'Search news, papers, authors...'. A filter section includes tags like 'All tags', 'Academic', 'Survey', 'GitHub', 'Blog', 'Usecase', and 'Lab'. The main content area displays a list of items, with the first item titled 'autoresearch-cli' and a description: '**Autonomy level**: Scientist — The tool is described as an autonomous research loop that lets an AI coding agent modify code, run experiments, score metrics, and iterate automatically, which fits a full hypothesis→experiment→result→iteration workflow with minimal human intervention.' The item includes a 'Show more' link, a 'GitHub' link, and engagement metrics (1 like, 0 dislikes, 0 comments). A 'Read' button is also visible. The second item is titled 'Agent Exploration Toward Artificial General Intelligence'. On the right side, there's a 'Add useful link' panel with fields for 'Link', 'Title', and 'Overview', and a 'Tags' section with the same filter tags as the main list. An 'Add link' button is at the bottom of this panel. A 'Pinned' section at the very bottom shows 0 items.


ハンズオンの流れ



1. Discovery Agentの理解 with Weaveの基礎理解
2. 人手評価
3. 人手評価の結果をもとに、Coding Agent x Skills x Weaveでプロンプトを自動改善
4. オフライン評価体系をもとに、Coding Agent x Skills x Weaveでプロンプトを自動改善
5. オンラインモニタリング
6. Weaveの最新News

- 概要: <https://ai-eng-dojo.com/learn/agent-quality-handson/understand-the-agent>
- Lint (ソフトウェアの品質とAI推論部分の品質の話)
 - <https://ai-eng-dojo.com/learn/agent-quality/ai-product-testing>
- Weaveの基礎
- Weave.Model
 - Coding Agentに聞いてみる
 - “ResearcherAgent の構造を教えて”
- 1回回してみる
 - `uv run python main.py --max-tools 1`
 - ※ Dedicated Cloudの場合、weave Modelのversion管理にエラーがありますが、そのまま進めていけるので、今回はそのエラーは無視してください


生成AIの活用パターン



W&B Weave: World ClassのLLMOpsをチームに提供



- 入力・出力・メタデータ・コードをすべてトレース可能することでモニタリングとデバッグを容易に
- 評価の実行と追跡を中央で管理することで再現性とチーム間コラボレーションを向上
- モニタリングしながら継続的に品質の問題点を特定
- Weaveを導入することで、チームの開発プロセスをLLMOpsに沿わせることができる



Weave の基本機能



👁️ 可視化 (Observability)

エージェントのセッションやマルチターン対話から、アプリ内の個々の関数呼び出し・入出力までを追跡し、振る舞いの透明性と説明責任を高める

👤 バージョン管理

プロンプト・AI Agent・データ・評価スコアの自動バージョン管理

✅ 評価体系の構築 (offline evals)

品質担保に必須の評価体系を構築。AI Agentの性能を体系的に測定し、異なるプロンプト・モデルを横並びで比較・検証

💬 フィードバック収集


人手による判断・アノテーションを取得

🛡️ 本番モニタリング (online evals)

本番での LLM の安全性と品質を継続的に担保

📦 エンタープライズ要件への対応

データガバナンス／コンプライアンスを満たすスケーラブルな基盤を提供
マルチテナントSaaS・専用クラウド・オンプレミス
から選べる柔軟なデプロイメントオプションを提供



管理できる4つのアセット



Prompt

プロンプトのバージョン管理。変更履歴を追跡。



Dataset

評価用データセットの管理と再利用。



Scorer

スコアラーの管理。評価ロジックを資産化。



Model ◀ 要チェック

生成AIアプリのバージョン管理。Weave だけが提供。



weave.Model のバージョン管理

- * LLM アプリでは **API 呼び出し + システムプロンプト + ツール** の組み合わせが「モデル」として機能する。
- * **weave.Model** を継承し **predict / invoke** を定義するだけ。
- * モデル名・temperature・プロンプト・コード の変更が、呼び出すたびに **自動でバージョン管理** される(例: **v21**)。

🛡️ 任意の AI Agent をバージョン管理できるのは Weave だけ

https://docs.wandb.ai/weave/tutorial-weave_models

The screenshot displays the Weave web interface. On the left, a sidebar shows a tree view of the project structure, including 'ExtractDinos.invoke' and 'extract_dinos'. The main panel is titled 'ExtractDinos.invoke' and shows the 'Inputs' tab. The inputs are listed as follows:

Path	Value
self	ExtractDinos.v21
client	<openai.OpenAI object at 0x7f9eb1da8550>
model_name	gpt-4o
temperature	0.400000
system_prompt	Extract any dinosaur `name`, their `common_name`, names and whether its `diet` is a herbiv...
invoke	ExtractDinos.invoke:v8

Below the inputs, the 'code' tab is selected, showing the following Python code:


```
1 import weave
2 import json
3
4 @weave.op()
5 def extract_dinos(wmodel: weave.Model, sentence: str) -> dict:
6     response = wmodel.client.chat.completions.create(
7         model=wmodel.model_name,
8         temperature=wmodel.temperature,
9         messages=[
10             {
11                 "role": "system",
12                 "content": wmodel.system_prompt
13             },
14             {
15                 "role": "user",
16                 "content": sentence
17             }
18         ],
19         response_format={ "type": "json_object" }
20     )
```

At the bottom, the 'sentence' input is shown with the value: 'I watched as a Tyrannosaurus rex (T. rex) chased after a Triceratops (Trike), both carnivore and he...'

パラメータもコードも自動でバージョン管理される

Discovery Agentの理解 with Weaveの基礎の理解


生成AIの活用パターン



W&B Weave: World ClassのLLMOpsをチームに提供



- 入力・出力・メタデータ・コードをすべてトレース可能することでモニタリングとデバッグを容易に
- 評価の実行と追跡を中央で管理することで再現性とチーム間コラボレーションを向上
- モニタリングしながら継続的に品質の問題点を特定
- Weaveを導入することで、チームの開発プロセスをLLMOpsに沿わせることができる



Weave の基本機能



👁️ 可視化 (Observability)

エージェントのセッションやマルチターン対話から、アプリ内の個々の関数呼び出し・入出力までを追跡し、振る舞いの透明性と説明責任を高める

👤 バージョン管理

プロンプト・AI Agent・データ・評価スコアの自動バージョン管理

✅ 評価体系の構築 (offline evals)

品質担保に必須の評価体系を構築。AI Agentの性能を体系的に測定し、異なるプロンプト・モデルを横並びで比較・検証

💬 フィードバック収集

人手による判断・アノテーションを取得

🛡️ 本番モニタリング (online evals)

本番での LLM の安全性と品質を継続的に担保

📦 エンタープライズ要件への対応

データガバナンス／コンプライアンスを満たすスケーラブルな基盤を提供
マルチテナントSaaS・専用クラウド・オンプレミス
から選べる柔軟なデプロイメントオプションを提供

The screenshot shows the Weave observability interface. At the top, it says 'wandb-pmm > Projects > RetailSupportAgent > Calls'. Below this, there's a search bar and a 'Filter' button. The main table is titled 'RetailSupportAgent.predict Traces'. It has columns for 'Trace', 'Feedback', 'Status', 'chatid', 'formatted_date', 'question', 'self', and 'sessionid'. The table contains several rows of data, each representing a trace. A sidebar on the left shows navigation options like 'Traces', 'Inputs', 'Outputs', 'Prompts', 'Models', 'Sessions', 'Scores', and 'More'. A user profile 'Russell Ratshin wandb' is visible in the top right corner.

Trace	Feedback	Status	chatid	formatted_date	question	self	sessionid
RetailSupportAgent.predict 1843	👍 1	🟢	321	February 24, 2025	yes please	RetailSupport...	86b88f0a-f2...
RetailSupportAgent.predict #82x		🟢	-1	February 24, 2025	hello, i'd like to ret...	RetailSupport...	86b88f0a-f2...
RetailSupportAgent.predict 29e8		🟢	-1	February 23, 2025	hello!	RetailSupport...	be4d7172-f2...
RetailSupportAgent.predict 4462	👍 1	🟢	319	February 23, 2025	yes please	RetailSupport...	a4c20b9e-f2...
RetailSupportAgent.predict 2758		🟢	-1	February 23, 2025	i'd like to return a c...	RetailSupport...	a4c20b9e-f2...
RetailSupportAgent.predict c78c	👍 1	🟢	318	February 23, 2025	yes please	RetailSupport...	45afdf0e-f23...
RetailSupportAgent.predict 64e8		🟢	-1	February 23, 2025	i'd like to return a c...	RetailSupport...	45afdf0e-f23...
RetailSupportAgent.predict 78c4		🟢	-1	February 23, 2025	hello, i'd like to ret...	RetailSupport...	716161a1-f2...
RetailSupportAgent.predict #63d		🟢	-1	February 23, 2025	hello, i'd like to ret...	RetailSupport...	605f44f8-f23...
RetailSupportAgent.predict 8cde		🟢	-1	February 23, 2025	hello, i'd like to ret...	RetailSupport...	31642956-f2...
RetailSupportAgent.predict #483		🟢	314	February 23, 2025	that's the one, plea...	RetailSupport...	1e55597a-f21...
RetailSupportAgent.predict 5f95		🟢	-1	February 23, 2025	hello, i'd like to ret...	RetailSupport...	1e55597a-f21...
RetailSupportAgent.predict e9e8		🟢					
RetailSupportAgent.predict 51e9		🟢					
RetailSupportAgent.predict #442		🟢					

```
trace.py

import weave
weave.init("my_project")

@weave.op()
def my_function(text: str) -> str :
    return f"Processed: {text}"

result = my_function("Hello, Weave!")
```

人手評価

評価体系構築の必要性和その難しさ



すぐに訪れる AI Agentの再開発

- 新しいフレームワークやライブラリが出るたびに、既存のワークフローが壊れるリスク(レグレッション)
- LLMを変えると連携している下流処理が壊れる
- ユーザーからの要望反映期待値が短い


GSKのケーススタディ

評価体系を設ける必要性

- 変更の影響範囲を把握できない
- 改善効果を説明できない
- 自動改善もできない

その評価体系もすぐには構築できない

- 最初からデータがなく、明確な基準がないので少しずつ評価体系を作る必要がある



Demystifying evals for AI agents (Anthropic)

- `uv run python main.py --max-tools 10 --since month --rerun`
- Annotation queueで人手評価を3つ実施してみましょう


人手評価の結果をもとに、
Coding Agent x Skills x Weaveでプロンプトを自動改善

- W&B Skills・今回のSkillsを理解する
- Skillsを使ってみる
 - WeaveのAnnotation Queue "research_annotation"でfeedbackを付与したtraceとそのfeedback結果を使い、skills/annotation-improvement/SKILL.md を通じてプロンプトを改善してください。
- 再度実装し、比較
 - `uv run python main.py --max-tools 1 --rerun`

オフライン評価体系をもとに、
Coding Agent x Skills x Weaveでプロンプトを自動改善

柔軟な評価フレームワーク

- ハーネスおよびモデルの改善を、信頼性高く測定できる評価API
- 回帰を検知するための強力な評価比較・可視化機能
- イテレーション間の変更点を特定できるバージョン管理



KEY VALUE


各イテレーションで、ユーザーに影響が及ぶ前に回帰を検出し、より信頼性の高いエージェントをリリース



AI application / Evaluation
の自動バージョン管理

複数のメトリックを一覧で確認

AI Application	Evaluation	Accuracy 1	Accuracy 2	Safety	User experience	Cost	Latency
rag : ver2	eval : ver1						
rag : ver1	eval : ver1						
...	...						



Weave.Evaluateの基本



- データセット とスコアリング関数 を登録し、モデルを比較する枠組み
- 複数スコアラーを横並び で確認でき、評価体系とアプリのバージョンが自動で両方トラックされる

```
from weave import Evaluation

@weave.op()
def exact_match (expected, model_output):
    return {"match" : expected == model_output}

eval_job =
Evaluation (
    dataset=dataset,
    scorers=[exact_match],
)

await eval_job.evaluate(model)
```

[docs.wandb.ai/weave](https://docs.wandb.ai/weave/tutorial-eval) ·
[tutorial-eval](#)

EvaluationLogger — 柔軟なロギング



- コード中の **任意の地点** で評価情報を逐次記録できる軽量 API
- Dataset やスコアラーを事前に厳密定義しなくてよい。予測が出た時点で入力・出力・スコアを個別記録
- 複雑な Agent フローで特定ステップだけ評価 したい場合に有用。トークン・コストも自動集計

logger.py

```
from weave import EvaluationLogger

# 1) ロガーを初期化
eval_logger = EvaluationLogger (
    model= "my_model", dataset="my_dataset" ,
)

# 2) 予測とスコアを逐次ログ
for sample in dataset:
    pred = eval_logger.log_prediction (
        inputs=sample["inputs"],
        output=output)
    pred.log_score(scorer="correctness", score=...)

# 3) サマ리를ログ
eval_logger.log_summary({"overall_score": 0.98})
```

- 評価体系を作る意義
- 今回の評価対象
- 実装してみる
 - Dedicated, onpremiseで実装する場合: データ登録から
 - `uv run python evaluate.py`
- Skillsで改善する
 - `skills/offline-eval-improvement/SKILL.md` を利用し、Weave Eval <Weave EvalのCall id> を改善してください。3回改善を繰り返し、スコア向上を目指してください
- Prompt管理 alias ([例](#))


オンラインモニタリング

Background...



オフライン開発は遅く、現実世界のすべてのシナリオをカバーできない

オフライン開発



本番環境の現実



Built-inシグナルによる エージェントモニタリング

- **Built-in・カスタム LLM as a Judge**でエージェントのやり取りを自動で記録・分類
- **アラート**で重要な情報をSlack通知やWebhook自動化で即時に届ける

Rating templates

User satisfaction

User Good Intent

Safe-for-Work

Response Quality

Tag templates

User Frustration


Jailbreaking

NSFW

Low Quality
Response

KEY VALUE

- **失敗モードを高精度で検出し**、数百万件規模のエージェント挙動から重大な問題を見逃さない




- [Monitoringの設定例](#)
- [Signals例](#)

Weaveの最新News

Background...



LLM call、tool call、agent invocation、token usage、
model nameなどを標準的に記録するための
GenAI semantic conventionsが
OpenTelemetry側で定義された




エージェントネイティブな高度ビューと分析

- GenAI semantic conventionsを利用し、エージェントのフレームワークに寄らず、エージェントトレースの高度なビューを実現
- マルチエージェントシステム全体の挙動を簡単に追跡

KEY VALUE

生ログでは埋もれてしまう障害障害の根本原因をすばやく発見

Blog: [New in W&B Weave: Observability and continuous improvement for production agents](#)



Background...



Coding Agentの普及にわたり、

- IT部門はコストを管理したい
- 利用者は有効な用途を知りたい・より良い使い方のインサイトが欲しい

そのために管理ツールが欲しいというニーズが出てきている

*50% of your tokens are wasted.
You don't know which 50%.*

Coding Agentのトレース


- Claude CodeやCodexの利用をWeaveでトレースすることが可能
- 過去の利用を自分で確認・チームで共有することができる
- W&B Skillsを利用することで、利用の分析も可能

<https://docs.wandb.ai/weave/guides/tracking/trace-agent-integrations>

今後、W&Bが社内のために開発したさらにCoding Agentのトレースに特化したツールも公開される予定です!!

Web page: <https://hivemind.wandb.tools/welcome>

Docs: <https://hivemind.wandb.tools/docs/overview>



Sandbox

- オンデマンドで分離されたコンピュート環境を作成・実行・破棄
- 各サンドボックスは独立したファイルシステム・ネットワーク・プロセス空間を提供
- セッション管理により複数のサンドボックスを効率的に運用可能

```
main.py

from wandb.sandbox import Sandbox

with Sandbox.run() as sandbox:
    process = sandbox.exec([
        "echo",
        "Hello from Serverless Sandboxes!"
    ]).result()

    print(process.stdout)
```



2026-06-09

最近リリースされた W&B Sandbox で安全な任意コード実行を試す

AI Agent

はじめに

今回のAKARI Tech Blogは、DX Solution事業本部 VPoEの丸尾 (@marumaru_akari) が担当します！

データ分析などで、LLM に任意 Python を実行させたい場面は増えていますが、ホスト上で動かすのは怖いものです。CoreWeave が公開した **Sandbox** はこの問題への解として位置づけられています。本記事では Sandbox の概要、Weave トレースを使った実行履歴の可視化と実例を扱います。

目次

- はじめに
- 1. W&B Serverless Sandbox とは
- 2. 最小サンプルと Weave トレース
- 3. OpenAI tool use と Sandbox の組み合わせ
- 4. 危険コードを安全に実行する
 - デモ1: /etc の中身を覗く
 - デモ2: /etc/pwd.lock を削除する
- 5. CSV をアップロードして分析・グラフを生成する
- まとめ
- We're hiring!

<https://tech.akariinc.co.jp/entry/2026/06/09/184352>